

MAT02036 - Amostragem 2

Aula 02 - Teoria Básica

Markus Stein

Departamento de Estatística, IME/UFRGS

2022/2

Housekeeping

- Aproveitem o momento presencial para tirar dúvidas
- Se estivéssemos no ensino remoto ou à distância
 - vocês poderiam estar somente ouvindo, sem interação
 - ou assistindo vídeos e material em outro momento
- Depois das aulas, rever material da aula passada
 - fazer exercícios
 - se preparar para a próxima aula

Aula passada

Notação	População	Amostra
Índice (rótulo)	$U = \{1, 2, \dots, i, \dots, N\}$	$s = \{i_1, i_2, \dots, i_n\}$
Característica	$Y_U = \{y_1, y_2, \dots, y_i, \dots, y_N\}$	$Y_s = \{y_{i_1}, y_{i_2}, \dots, y_{i_n}\}$
Total	$T = \sum_{i=1}^N y_i = \sum_{i \in U} y_i$	$\hat{T} = t(s) = t = \sum_{i \in s} y_i$
Média	$\bar{Y} = \frac{T}{N} = \frac{1}{N} \sum_{i \in U} y_i$	$\widehat{\bar{Y}} = \bar{y} = \frac{t(s)}{n} = \frac{1}{n} \sum_{i \in s} y_i$
Variância	$Var_y = \frac{1}{N} \sum_{i \in U} (y_i - \bar{Y})^2$	$var_y = \frac{1}{n} \sum_{i \in s} (y_i - \bar{y})^2$
Variância	$S_y^2 = \frac{1}{N-1} \sum_{i \in U} (y_i - \bar{Y})^2$	$s_y^2 = \frac{1}{n-1} \sum_{i \in s} (y_i - \bar{y})^2$

- Espaço amostral: $S = \{s_1, s_2, \dots, s_j, \dots, s_\nu\}$
- Plano amostral: $p(s)$, em que $\sum_{s \in S} p(s) = 1$
- Esperança em relação a $p(s)$: $E_p[t(s)] = \sum_{s \in S} t(s)p(s)$
- Variância em relação a $p(s)$: $Var_p[t(s)] = \sum_{s \in S} [t(s) - E_p(t)]^2 p(s)$

Aula passada

- Vimos que trabalhar com a distribuição $p(s)$ é complicado.
 - O número total, $\nu = \binom{N}{n}$, tamanho do conjunto S cresce muito rapidamente com N e com n .
 - Então trabalhamos com a **probabilidade de inclusão** da unidade i , π_i .
- **Probabilidade de inclusão** (de primeira ordem)

$$\pi_i = P(i \in s) = \sum_{s \ni i} p(s) > 0, \forall i \in U.$$

- **Estimador linear** do total populacional (não viesado sob π):

$$\hat{T}_w = \sum_{i \in s} w_i y_i = \sum_{i \in s} \frac{1}{\pi_i} y_i = \sum_{i \in s} \pi_i^{-1} y_i.$$

Teoria Básica e AAS

Teoria básica

- Vamos olhar um pouco mais para a ideia de trabalhar com **propabilidades de inclusão** π_i .
- π_i pode ser vista como o parâmetro da distribuição de probabilidades da variável aleatória R , para a i -ésima unidade.
- Definimos a variável indicadora R_i tal que

$$R_i = \begin{cases} 1, & i \in s \\ 0, & i \notin s \end{cases}$$

para todo $i \in U$.

- A variável R_i é indicadora do evento 'inclusão da unidade i na amostra s '.

Teoria básica

Exemplo: estimação do total e AAS

- Para $N = 4$ e $n = 2$, as seis amostras possíveis podem ser representadas pelas indicadoras por

Representação de cada amostra possível pelas variáveis indicadoras

Amostra	Unidades na Amostra	R_1	R_2	R_3	R_4
1	$s_1 = \{1; 2\}$	1	1	0	0
2	$s_2 = \{1; 3\}$	1	0	1	0
3	$s_3 = \{1; 4\}$	1	0	0	1
4	$s_4 = \{2; 3\}$	0	1	1	0
5	$s_5 = \{2; 4\}$	0	1	0	1
6	$s_6 = \{3; 4\}$	0	0	1	1

- Cada amostra fica univocamente determinada pelas variáveis indicadoras R_1, R_2, \dots, R_N correspondentes.

Teoria básica

- As variáveis indicadoras R dependem da amostra s ,
 - não indicamos explicitamente em nossa notação, mas temos que

$$\pi_i(s) = P(i \in s) = \sum_{s \ni i} p(s) = P(R_i = 1) = E_p(R_i), \forall i \in U$$

- Relembre: as **probabilidades de inclusão** π_i são ditas de **primeira ordem**.
- Sob essa ótica, precisamos também definir **probabilidades de inclusão de segunda ordem**, denotadas π_{ij} , dadas por

$$\pi_{ij} = P[(i, j) \in s] = \sum_{s \ni (i, j)} p(s) = P(R_{ij} = 1) = E_p(R_{ij}), \forall (i, j) \in U,$$

em que $R_{ij} = R_i R_j$.

- Note que quando $i = j$, $\pi_{ij} = \pi_{ii} = \pi_i, \forall i \in U$.

Teoria básica

- Além da propriedade de valor esperado das variáveis aleatórias indicadoras R_i , pode-se também deduzir que:

$$Var_p(R_i) = \pi_i(1 - \pi_i)$$

e

$$Cov_p(R_i, R_j) = \pi_{ij} - \pi_i\pi_j.$$

- Um método geral de prova em amostragem se baseia num uso inteligente das variáveis indicadoras R_1, R_2, \dots, R_N .
- Uma propriedade importante dessas variáveis indicadoras é que:

$$\sum_{i \in s} R_i = \sum_{i \in U} R_i.$$

Teoria básica

- Segue também que:

$$\sum_{i \in s} y_i = \sum_{i \in s} R_i y_i = \sum_{i \in U} R_i y_i.$$

- Convertemos a soma amostral que,
 - antes de selecionada a amostra, tem parcelas aleatórias,
 - em uma soma na população, onde as parcelas são conhecidas mas dependem das R_i .

Estimador linear do total

Estimador linear do total

- Considere o total populacional $T = \sum_{i \in U} y_i$ como parâmetro alvo;
- Um **estimador linear** de T é sempre da forma

$$\hat{T}_w = \sum_{i \in s} w_i y_i = \sum_{i \in U} R_i w_i y_i$$

onde w_i é o *peso amostral* da unidade i .

- Para que o estimador linear \hat{Y}_w de Y seja **sempre** não viciado, é preciso que:

$$E_p(\hat{T}_w) = T \Leftrightarrow \sum_{i \in U} E_p(R_i) w_i y_i = \sum_{i \in U} y_i \Leftrightarrow \sum_{i \in U} \pi_i w_i y_i = \sum_{i \in U} y_i.$$

- Esta relação só será válida para quaisquer valores populacionais y_i da variável de pesquisa caso $\pi_i \times w_i = 1, \forall i \in U$.

Estimador linear do total

Exemplo: AAS sem reposição

Considere o plano amostral AASs para estimar o total populacional T usando o estimador $\hat{T}_w = \hat{T}_{AASs}$.

- A. Calcule as probabilidades de inclusão de primeira ordem π_i .
- B. Calcule as probabilidades de inclusão de segunda ordem π_{ij} .
- C. Mostre que \hat{T}_{AASs} é não viesado para T
 - C.1. usando o plano amostral $p(s)$.
 - C.2. usando a probabilidade de inclusão π .

Estimador linear do total

Exemplo: AAS sem reposição

- A. Temos que para a AASs $p(s) = ?$, para todo $s \in S$,
- pois o número de possíveis amostra é dado por $\nu = ? \dots$
 - então $\pi_i = ?$
- B. $\pi_{ij} = ?$
- C.1. Olhar Cochran... ou slides Prof. Rodrigo.
- C.2. Olhar propriedades do estimador linear acima.

Estimador linear do total

Exemplo: AAS sem reposição

- Qual a distribuição amostral do estimador do total \hat{T}_w ?
 - Ou da média $\bar{y}_w = \widehat{T}_w$?
- TCL para amostras de populações finitas?
 - $\sqrt{n}(\hat{T}_w - T) \xrightarrow{d} ?$
 - condições? quando $N \rightarrow \infty, n \rightarrow \infty, f = \frac{n}{N}$ limitado menor que 1?

Ver Bolfarine e Bussab capítulo 10, Cochran , Slides do Prof. Rodrigo, ...

Quem tiver interesse em aspectos teóricos podemos revisar!

Estimador linear do total

Estimador Horvitz-Thompson

- Com pesos básicos d_i , o estimador não viciado de total fica dado pelo conhecido *estimador de Horvitz-Thompson* ou *estimador HT*:

$$\hat{T}_{HT} = \sum_{i \in s} d_i y_i = \sum_{i \in s} \pi_i^{-1} y_i = \sum_{i \in s} y_i / \pi_i$$

- Assim, o estimador linear do total $\hat{T}_w = \sum_{i \in s} w_i y_i$ será **sempre** não viciado se:
 - $w_i = \pi_i^{-1} = 1/\pi_i = d_i, \forall i \in U$.
 - os pesos amostrais d_i são chamados de **pesos básicos** do plano amostral.
 - outros pesos além dos definidos pelo delineamento, d_i , podem ser úteis na prática.
 - A notação w_i é reservada para designar pesos genéricos que podem ser aplicados para a obtenção de estimadores (viciados ou não).

Estimador linear do total

Estimador Horvitz-Thompson

- Este estimador está definido para qualquer
 - variável de pesquisa y e
 - para qualquer *plano amostral probabilístico* p , ou $\pi_i > 0, \forall i \in U$.
- **Amostragem probabilística** de populações finitas nos garante certa confiança de sempre dispor de estimadores não viciados como o *HT*.
- Lembrando: o estimador **HT** faz uso das probabilidades de inclusão π (implicadas pelo plano amostral $p(s)$),
 - mas depende através das probabilidades de inclusão de primeira ordem π_i ,
 - uma condição geralmente simples de satisfazer na prática da pesquisa.

Estimador linear do total

Estimador Horvitz-Thompson

Propriedades do estimador de Horvitz-Thompson

O *estimador de Horvitz-Thompson* é *não viciado* para estimar o total, ou seja, $E_p(\hat{T}_{HT}) = Y$.

Prova:

$$E_p(\hat{T}_{HT}) = E_p \left[\sum_{i \in U} R_i y_i / \pi_i \right] = \sum_{i \in U} [E_p(R_i) y_i / \pi_i] = \sum_{i \in U} y_i = Y$$

Esta propriedade vale para qualquer população U , variável de interesse y e plano amostral p , desde que $\pi_i > 0, \forall i \in U$.

Estimador linear do total

Estimador Horvitz-Thompson

Propriedades do estimador de Horvitz-Thompson

A variância do estimador Horvitz-Thompson para o total é dada por:

$$\begin{aligned} Var_{HT}(\hat{T}_{HT}) &= \sum_{i \in U} \sum_{j \in U} \left(\frac{\pi_{ij}}{\pi_i \pi_j} - 1 \right) y_i y_j \\ &= \sum_{i \in U} \sum_{j \in U} \left(\frac{d_i d_j}{d_{ij}} - 1 \right) y_i y_j \end{aligned}$$

onde $d_{ij} = \pi_{ij}^{-1}$.

Esta é a chamada forma de Horvitz-Thompson da variância. Existe uma outra forma para esta variância, que vamos conhecer mais adiante.

Estimador linear do total

Estimador Horvitz-Thompson

Propriedades do estimador de Horvitz-Thompson

Prova:

$$\begin{aligned} Var_{HT}(\hat{T}_{HT}) &= Var_p \left(\sum_{i \in U} R_i \frac{1}{\pi_i} y_i \right) \\ &= \sum_{i \in U} \sum_{j \in U} Cov_p(R_i, R_j) \left(\frac{y_i}{\pi_i} \right) \left(\frac{y_j}{\pi_j} \right) \\ &= \sum_{i \in U} \sum_{j \in U} (\pi_{ij} - \pi_i \pi_j) \left(\frac{y_i}{\pi_i} \frac{y_j}{\pi_j} \right) \\ &= \sum_{i \in U} \sum_{j \in U} \left(\frac{\pi_{ij}}{\pi_i \pi_j} - 1 \right) y_i y_j \\ &= \sum_{i \in U} \sum_{j \in U} \left(\frac{d_i d_j}{d_{ij}} - 1 \right) y_i y_j \end{aligned}$$

Estimador linear do total

Estimador Horvitz-Thompson

Propriedades do estimador de Horvitz-Thompson

Um estimador não viciado da variância do estimador **HT** do total é dado por:

$$\begin{aligned}\widehat{Var}_{HT}(\widehat{T}_{HT}) &= \sum_{i \in s} \sum_{j \in s} \frac{(\pi_{ij} - \pi_i \pi_j)}{\pi_{ij}} \left(\frac{y_i}{\pi_i} \frac{y_j}{\pi_j} \right) \\ &= \sum_{i \in s} \sum_{j \in s} (d_i d_j - d_{ij}) y_i y_j\end{aligned}$$

- Este estimador da variância foi obtido usando o princípio dos estimadores tipo Horvitz-Thompson do total.
 - Agora, como estimamos uma soma dupla na população, os pesos das parcelas nessa soma dependem das probabilidades de inclusão de **segunda ordem** π_{ij} .
 - Para ser viável, $p(s)$ tem que satisfazer a condição adicional de que $\pi_{ij} > 0 \forall i \neq j \in U$ (estritamente positivas).

Considerações

Estimador linear do total

Comentários sobre estimação de totais e respectivas variâncias em **amostragem probabilística**:

- É possível sempre **estimar sem vício um total populacional** usando uma soma amostral π -ponderada, o estimador **HT** do total.
- Expressões de variância para **avaliar a qualidade do estimador de total** sob distintas situações (população, variável) para qualquer plano amostral.
- Estimar muitos **outros parâmetros populacionais** (tais como médias, proporções e razões) com os resultados vistos na estimação de totais.
- Derivar estimadores não viciados do total populacional e da variância do estimador **HT** de total para **distintos planos amostrais** como **casos especiais** da teoria geral apresentada.
 - conveniente para a **estimação de variâncias**, cujas expressões gerais dependem de somas duplas difíceis de calcular para n grande.
 - **expressões para cada um dos planos amostrais** específicos são úteis porque permitem simplificar os cálculos da estimação de variâncias.

Estimador linear do total

- Em **planos amostrais equiponderados** (em que as probabilidades de inclusão π_i são todas iguais);
 - os pesos w_i para estimação de médias ficam todos iguais a $1/n$;
 - uma vantagem pois a tarefa de estimação fica simplificada.
- Estimadores HT do total, média e respectivas variâncias (\$N\$ conhecido):

Estimadores HT	Variâncias dos Estimadores HT
$\hat{T}_{HT} = \sum_{i \in s} d_i y_i = \sum_{i \in s} y_i / \pi_i$	$\widehat{Var}_{HT}(\hat{T}_{HT}) = \sum_{i \in s} \sum_{j \in s} \frac{(\pi_{ij} - \pi_i \pi_j)}{\pi_{ij}} \left(\frac{y_i}{\pi_i} \frac{y_j}{\pi_j} \right)$
$\bar{y}_{HT} = \hat{T}_{HT} / N = \sum_{i \in s} d_i y_i / N$	$\widehat{Var}_{HT}(\bar{y}_{HT}) = \widehat{Var}_{HT}(\hat{T}_{HT}) / N^2$

Quando N **não for conhecido**, podemos usar o **estimador de razão**

$$\bar{y}^R = \frac{\sum_{i \in s} d_i y_i}{\sum_{i \in s} d_i} = \sum_{i \in s} w_i^R y_i \text{ e } \widehat{Var}_{HT}(\bar{y}^R) = \frac{1}{\widehat{N}_{HT}^2} \sum_{i \in s} \sum_{j \in s} \frac{(\pi_{ij} - \pi_i \pi_j)}{\pi_{ij}} \left(\frac{y_i - \bar{y}^R}{\pi_i} \right) \left(\frac{y_j - \bar{y}^R}{\pi_j} \right)$$

Expressão alternativa para a variância - Sen-Yates-Grundy

$$\widehat{Var}_{SYG}(\hat{Y}_{HT}) = \sum_{i \in s} \sum_{j > i} \left(\frac{\pi_i \pi_j - \pi_{ij}}{\pi_{ij}} \right) \left(\frac{y_i}{\pi_i} - \frac{y_j}{\pi_j} \right)^2$$

Laboratório de

Exercício

Considere a população com $N = 6$ domicílios listada com os respectivos valores de variáveis de interesse.


Valores de variáveis de interesse para cada domicílio da população

Domicílio	Renda (R\$)	NO. de Moradores	No. de Trabalhadores
1	800	2	2
2	4.200	4	3
3	1.600	2	1
4	500	2	1
5	900	4	2
6	2.000	1	1
Total	10.000	15	10

Exercício

1. Para cada variável de interesse (Renda, Número de Moradores e Número de Trabalhadores), calcule os seguintes parâmetros populacionais: total, média e variância.
2. Liste o conjunto S de todas as amostras possíveis de tamanho $n = 2$ da população, considerando apenas **amostras de unidades distintas**.
3. Supondo que todas as amostras listadas no conjunto S são **equiprováveis** (Plano A), calcule:
 - As probabilidades de inclusão das unidades.
 - As probabilidades de inclusão dos pares de unidade.
 - Os valores possíveis para o estimador Horvitz-Thompson do total populacional para a variável Renda.
 - O valor esperado e a variância para o estimador Horvitz-Thompson do total populacional para a variável Renda.

Exercício

4. Considere agora que o conjunto S é formado somente pelas amostras $(1; 2), (2; 3), (2; 4), (2; 5)$ e $(2; 6)$, tendo cada uma delas probabilidade $1/5$ de ser a amostra selecionada (Plano B). Repita os cálculos do item 3 para o novo plano amostral.
5. Faça gráficos dos valores possíveis do estimador de total sob os dois planos amostrais para comparar as respectivas distribuições.
6. Use os resultados obtidos em 3 e 4 para comparar os dois planos amostrais e indique qual deles seria preferível usar, caso fosse necessário amostrar duas unidades distintas da população ($n = 2$) para estimar o total da Renda. Justifique. 

Exercício

```
## dados da populacao e plano amostral
N <- 6                # no. elementos na pop.
i <- 1:N              # indice dos elementos da pop.
n <- 2                # no. elementos na amostra
nu <- choose(N, n)    # no. possíveis amostras
j <- 1:nu              # indice dos elementos dos espaço amostral
S <- combn(N,n)        # espaço amostral
p1s <- 1/nu            # AAS

## variaveis
renda <- c(800, 4200, 1600, 500, 900, 2000)
moradores <- c(2, 4, 2, 2, 4, 1)
trabalhadores <- c(2, 3, 1, 1, 2, 1)
```

Para casa

- Continuar o Exemplo
- Continuar o Exercício
- Rever os slides.
- Ler seção 11.1 a 11.3 do livro 'Amostragem: Teoria e Prática Usando R'.

Próxima aula

- Amostragem Estratificada
 - Características
 - Parâmetros
 - Estimadores

Muito obrigado!



Fonte: imagem do livro *Combined Survey Sampling Inference: Weighing of Basu's Elephants: Weighing Basu's Elephants*.

Amostragem aleatória simples

Amostragem aleatória simples COM reposição

- Na **Amostragem Aleatória Simples com reposição** (AASc) as unidades da população têm a mesma chance de ser incluídas na amostra em cada sorteio, e essa probabilidade é igual a $1/N$.

- **Plano amostral**

- Existem N^n amostras distintas em S , então

$$p(s) = 1/N^n, \forall s \in S.$$

- **Probabilidades de inclusão:**

- $\pi_i = P(i \in s) = 1 - P(i \notin s) = 1 - \left(1 - \frac{1}{N}\right)^n.$
 - $\pi_{ij} = 1 - 2\left(1 - \frac{1}{N}\right)^n + \left(1 - \frac{2}{N}\right)^n$, para $i, j = 1, \dots, N.$

Amostragem aleatória simples COM reposição

- A variável Q_i denota a 'qtd. de vezes a unidade i aparece na amostra s ',

$$Q_i \sim \text{Binomial}(n, 1/N)$$

- $E_{AAS}[Q_i] = n \frac{1}{N}$
- $Var_{AAS}[Q_i] = n \frac{1}{N} \left(1 - \frac{1}{N}\right)$
- $Cov_{AAS}[Q_i, Q_j] = -\frac{n}{N^2}$ (*propriedade da multinomial*)

Estimador não viciado (ENV) para:

- o **total** populacional T : $\hat{T}_{AASc} = N\bar{y} = N \sum_{i \in s} \frac{y_i}{n}$
- a **média** populacional \bar{Y} : $\widehat{\bar{Y}}_{AASc} = \frac{1}{n} \sum_{i \in s} y_i = \bar{y}$
- a **variância** populacional Var_y : $\widehat{Var}_{y,AASc} = \frac{1}{n-1} \sum_{i \in s} (y_i - \bar{y})^2 = \hat{S}_y^2$

Amostragem aleatória simples COM reposição

- **Variância dos Estimadores**

- $Var_{AASc}(\hat{T}_{AASC}) = N^2 Var_y / n$

- $Var_{AASc}(\bar{y}) = Var_y / n$

em que $Var_y = \frac{1}{N} \sum_{i \in U} (y_i - \bar{Y})^2 = \frac{N-1}{N} S^2$

- **ENV da Variância dos Estimadores**

- $\widehat{Var}_{AASc}(\hat{T}_{AASC}) = N^2 \hat{S}_y^2 / n$

- $\widehat{Var}_{AASc}(\bar{y}) = \hat{S}_y^2 / n$

em que $\hat{S}_y^2 = \frac{1}{n-1} \sum_{i \in s} (y_i - \bar{y})^2 = s_y^2$.

Amostragem aleatória simples SEM reposição

- Na **Amostragem Aleatória Simples sem reposição (AASs)** cada unidade da população pode aparecer na amostra no máximo uma única vez.

- **Plano amostral sob AASs**

- Existem $\binom{N}{n} = \frac{N!}{n!(N-n)!}$ amostras distintas em S , então

$$p(s) = 1/\binom{N}{n}, \forall s \in S.$$

- **Probabilidades de inclusão sob AASs**

- $\pi_i = n/N > 0, \forall i \in U$, desde que $n > 0$.
 - $f = n/N$ é chamada de **fração amostral** ou **taxa de amostragem**.
 - Estimação de variância sem vício requer $\pi_{ij} > 0, \forall i, j \in U$.

$$\pi_{ij} = \frac{n(n-1)}{N(N-1)} > 0, \forall i \neq j \in U.$$

- Sob **AASs**, as probabilidades de inclusão π_i e π_{ij} não dependem de i ou j , e essa é a razão da simplicidade desse plano amostral.

Amostragem aleatória simples SEM reposição

- A variável R_i , indicadora do evento 'inclusão da unidade i na amostra s ', sob **AASs**
 - $E_{AAS}[R_i] = \frac{n}{N}$
 - $Var_{AAS}[R_i] = \frac{n}{N} \left(1 - \frac{n}{N}\right)$
 - $Cov_{AAS}[R_i, R_j] = \frac{n(n-1)}{N(N-1)} - \left(\frac{n}{N}\right)^2 = \frac{n}{N} \left(1 - \frac{n}{N}\right) \left(-\frac{1}{N-1}\right)$

Estimador não viciado (ENV) para:

- o **total** populacional T : $\hat{T}_{HT} = \sum_{i \in s} \frac{y_i}{n/N} = \frac{N}{n} \sum_{i \in s} y_i = N\bar{y} = \hat{T}_{AAS}$
- a **média** populacional \bar{Y} : $\widehat{\bar{Y}}_{AAS} = \frac{1}{n} \sum_{i \in s} y_i = \bar{y}$
- a **variância** populacional Var_y : $\widehat{Var}_{y,AAS} = \frac{N-1}{N} \hat{S}_y^2$,

pois \hat{S}_y^2 é ENV de S_y^2 na AASs.

Amostragem aleatória simples SEM reposição

- **Variância dos Estimadores**

- $Var_{AAS}(\hat{T}_{AASs}) = N^2 \left(1 - \frac{n}{N}\right) \frac{S^2}{n} = N^2 \left(\frac{1}{n} - \frac{1}{N}\right) S^2$

- $Var_{AAS}(\bar{y}) = \left(1 - \frac{n}{N}\right) \frac{S^2}{n} = \left(\frac{1}{n} - \frac{1}{N}\right) S^2$

onde $S_y^2 = \frac{1}{N-1} \sum_{i \in U} (y_i - \bar{Y})^2$, como já definido.

- **ENV da Variância dos Estimadores**

- $\widehat{Var}_{AAS}(\hat{T}_{AAS}) = N^2 \left(1 - \frac{n}{N}\right) \frac{\hat{S}_y^2}{n} = N^2 \left(\frac{1}{n} - \frac{1}{N}\right) \hat{S}_y^2$

- $\widehat{Var}_{AAS}(\bar{y}) = \left(\frac{1}{n} - \frac{1}{N}\right) \hat{S}_y^2$

onde $\hat{S}_y^2 = \frac{1}{n-1} \sum_{i \in s} (y_i - \bar{y})^2$, como já definido.

Amostragem aleatória simples SEM reposição

Considerações

1. O termo $(1 - n/N) = (1 - f)$ é chamado de **fator de correção para população finita**.
 - Quando $n/N \rightarrow 1$, o tamanho da amostra se aproximando do tamanho da população, então $(1 - n/N) \rightarrow 0$.
 - Ou seja: com amostras grandes as variâncias das estimativas tendem a ser pequenas.
2. Se a fração amostral $f = n/N$ for pequena (da ordem de 1% ou 2%), então a **correção de população finita** pode ser ignorada, pois $(1 - f) \doteq 1$.
 - Quando $f \doteq 0$, a AASse AASc (com reposição) tem comportamento semelhante em relação à precisão das estimativas.
 - *Intuitivamente*, sempre que n for muito **pequeno** em relação ao N a probabilidade de uma unidade i da população ser selecionada mais de uma vez é pequena.

Amostragem aleatória simples SEM reposição

Distribuição da média amostral

- Repetições do plano amostral $p(s)$ segundo AASs, \bar{y} tem uma **distribuição de probabilidades exata**, que **depende**:
 - da distribuição de y na população,
 - do tamanho da amostra n e
 - do plano amostral $p(s)$, que neste caso, é AASs.
- Isto resulta numa situação complicada, que pode ser resolvida considerando a **Distribuição Assintótica da Média Amostral**.
- Se n for **grande** e $f = n/N$ for pequena, o *Teorema Central do Limite* (Hajek, 1960) sugere uma aproximação

$$\frac{\bar{y} - E_{AAS}(\bar{y})}{\sqrt{Var_{AAS}(\bar{y})}} = \frac{\bar{y} - \bar{Y}}{\sqrt{\left(\frac{1}{n} - \frac{1}{N}\right) S_y^2}} \approx Normal(0; 1),$$

onde $Normal(0; 1)$ denota uma variável aleatória com distribuição normal padrão.

[*] Para detalhes ver Cochran(1977), Seções 2.8 e 2.15, ou Sarndal(1992), Seção 2.11.

Amostragem aleatória simples SEM reposição

Distribuição da média amostral

- Podemos construir **intervalos de confiança**(IC) para \bar{Y} .
 - Um IC de nível $(1 - \alpha)$ para \bar{Y} é dado por

$$IC_{AAS}(\bar{Y}; 1 - \alpha) = \left[\bar{y} \mp z_{\alpha/2} \sqrt{\widehat{Var}_{AAS}(\bar{y})} \right]$$

onde $z_{\alpha/2}$ é o quantil $1 - \frac{\alpha}{2}$, que deixa área $\alpha/2$ à sua direita.

- A **semiamplitude** do IC fornece uma ideia da **margem de erro** que se tem ao estimar o parâmetro.

$$\widehat{ME}_{AAS}(\bar{y}) = z_{\alpha/2} \sqrt{\widehat{Var}_{AAS}(\bar{y})}.$$

- A **margem de erro** pode ser **estimada** a partir da amostra selecionada e observada.
- **Amostragem probabilística** fornece indicativos da **incerteza associada a estimativas**, além de estimativas pontuais.

Resumo da notação

Estimadores AASc	Estimadores AASs
$\hat{T}_{AASc} = \frac{N}{n} \sum_{i \in s} y_i = N \bar{y}$	$\hat{T}_{AASs} = \frac{N}{n} \sum_{i \in s} y_i = N \bar{y}$
$\bar{y} = \frac{1}{n} \sum_{i \in s} y_i$	$\bar{y} = \frac{1}{n} \sum_{i \in s} y_i = \hat{\bar{T}}_{AASs}$
$\widehat{Var}_{AASc}(\hat{T}_{AASc}) = N^2 \hat{S}_y^2 / n$	$\widehat{Var}_{AASs}(\hat{T}_{AASs}) = N^2 \left(\frac{1}{n} - \frac{1}{N} \right) \hat{S}_y^2$
$\widehat{Var}_{AASc}(\bar{y}) = \hat{S}_y^2 / n$	$\widehat{Var}_{AASs}(\bar{y}) = \left(\frac{1}{n} - \frac{1}{N} \right) \hat{S}_y^2$

em que $\hat{S}_y^2 = \frac{1}{n-1} \sum_{i \in s} (y_i - \bar{y})^2$.

Estimadores HT	Variâncias dos Estimadores HT
$\hat{T}_{HT} = \sum_{i \in s} d_i y_i = \sum_{i \in s} y_i / \pi_i$	$\widehat{Var}_{HT}(\hat{T}_{HT}) = \sum_{i \in s} \sum_{j \in s} \frac{(\pi_{ij} - \pi_i \pi_j)}{\pi_{ij}} \left(\frac{y_i}{\pi_i} \frac{y_j}{\pi_j} \right)$
$\bar{y}_{HT} = \hat{T}_{HT} / N = \sum_{i \in s} d_i y_i / N$	$\widehat{Var}_{HT}(\bar{y}_{HT}) = \widehat{Var}_{HT}(\hat{T}_{HT}) / N^2$

Referências

Slides baseados nos Capítulos 3 e 4 do livro

- Amostragem: Teoria e Prática Usando o R

Citações do Capítulo

- Cochran(1977)
- Fuller(2009)
- Hajeck(1960)
- Horvitz(1952)
- Sarndal(1992)
- Sen(1953)
- Yates(1953)
- Yates e Grundy (1953)