

MAT02036 - Amostragem 2

Aula 03 - Amostragem Estratificada - Introdução e Estimação

Markus Stein

Departamento de Estatística, IME/UFRGS

2022/2

Housekeeping

- Aproveitem o momento presencial para tirar dúvidas
- Se estivéssemos no ensino remoto ou à distância
 - vocês poderiam estar somente ouvindo, sem interação
 - ou assistindo vídeos e material em outro momento
- Depois das aulas, rever material da aula passada
 - fazer exercícios
 - se preparar para a próxima aula

Aula passada

- Variável R_i indicadora do evento '**inclusão** da unidade i na amostra s '.

$$R_i = \begin{cases} 1, & i \in s \\ 0, & i \notin s \end{cases}, \forall i \in U.$$

- Probabilidades de inclusão de **primeira ordem**.

$$\pi_i(s) = P(i \in s) = \sum_{s \ni i} p(s) = P(R_i = 1) = E_p(R_i), \forall i \in U$$

- Probabilidades de inclusão de **segunda ordem**, denotadas π_{ij} , dadas por

$$\pi_{ij} = P[(i, j) \in s] = \sum_{s \ni (i, j)} p(s) = P(R_{ij} = 1) = E_p(R_{ij}), \forall (i, j) \in U,$$

- Variância e covariância de R

$$Var_p(R_i) = \pi_i(1 - \pi_i) \text{ e } Cov_p(R_i, R_j) = \pi_{ij} - \pi_i\pi_j.$$

Aula passada

- **Estimador linear** do total T : $\hat{Y}_w = \sum_{i \in s} w_i y_i = \sum_{i \in U} R_i w_i y_i$.
- Para que \hat{T}_w seja **sempre** não viciado:

$$E_p(\hat{T}_w) = T \Leftrightarrow \sum_{i \in U} E_p(R_i) w_i y_i = \sum_{i \in U} y_i \Leftrightarrow \sum_{i \in U} \pi_i w_i y_i = \sum_{i \in U} y_i.$$

- Válida para quaisquer y_i se $\pi_i \times w_i = 1, \forall i \in U$.
- Estimador **Horvitz-Thompson**: com pesos básicos d_i , para o total Y

$$\hat{T}_{HT} = \sum_{i \in s} d_i y_i = \sum_{i \in s} \pi_i^{-1} y_i = \sum_{i \in s} y_i / \pi_i$$

- O estimador linear do total $\hat{T}_w = \sum_{i \in s} w_i y_i$ será **sempre não viciado** se:

$$w_i = \pi_i^{-1} = 1/\pi_i = d_i, \forall i \in U.$$

- **Distribuição amostral**, resultados assintóticos, ...

Aula passada

Estimadores AASc	Estimadores AASs
$\hat{T}_{AASc} = \frac{N}{n} \sum_{i \in s} y_i = N \bar{y}$	$\hat{T}_{AASs} = \frac{N}{n} \sum_{i \in s} y_i = N \bar{y}$
$\bar{y} = \frac{1}{n} \sum_{i \in s} y_i$	$\bar{y} = \frac{1}{n} \sum_{i \in s} y_i = \frac{\hat{T}_{AASs}}{N}$
$\widehat{Var}_{AASc}(\hat{T}_{AASc}) = N^2 \hat{S}_y^2 / n$	$\widehat{Var}_{AASs}(\hat{T}_{AASs}) = N^2 \left(\frac{1}{n} - \frac{1}{N} \right) \hat{S}_y^2$
$\widehat{Var}_{AASc}(\bar{y}) = \hat{S}_y^2 / n$	$\widehat{Var}_{AASs}(\bar{y}) = \left(\frac{1}{n} - \frac{1}{N} \right) \hat{S}_y^2$

em que $\hat{S}_y^2 = \frac{1}{n-1} \sum_{i \in s} (y_i - \bar{y})^2$.

Estimadores HT	Variâncias dos Estimadores HT
$\hat{T}_{HT} = \sum_{i \in s} d_i y_i = \sum_{i \in s} y_i / \pi_i$	$\widehat{Var}_{HT}(\hat{T}_{HT}) = \sum_{i \in s} \sum_{j \in s} \frac{(\pi_{ij} - \pi_i \pi_j)}{\pi_{ij}} \left(\frac{y_i}{\pi_i} \frac{y_j}{\pi_j} \right)$
$\bar{y}_{HT} = \hat{T}_{HT} / N = \sum_{i \in s} d_i y_i / N$	$\widehat{Var}_{HT}(\bar{y}_{HT}) = \widehat{Var}_{HT}(\hat{T}_{HT}) / N^2$

Amostragem Estratificada

Amostragem Estratificada

O método geral

- **Amostragem estratificada** - AE utiliza **informação auxiliar** relevante para **dividir** a população U em H **grupos** disjuntos e exaustivos,
 - geralmente mais homogêneos em relação à(s) variável(is) de interesse, chamados *estratos*.
- Assumimos uma partição da população U (em H subconjuntos mutuamente exclusivos e exaustivos).
 - U_h : unidades pertencentes ao estrato h , para $h = 1, 2, \dots, H$.

$$U = \bigcup_{h=1}^H U_h \quad \text{e} \quad U_h \cap U_k = \emptyset, \forall h \neq k.$$

- Seja N_h o tamanho de U_h , O tamanho total da população é dado por

$$N = N_1 + \dots + N_h + \dots + N_H = \sum_{h=1}^H N_h.$$

Amostragem Estratificada

O método geral

- Para ser viável, as **variáveis de estratificação** (usadas para dividir a população em estratos) precisam:
 - estar **disponíveis** para todas as unidades da **população** da qual se vai selecionar a amostra.
- variáveis geográficas,
 - como as **unidades da federação** ou **municípios**,
- outros tipos,
 - tais como sexo, idade,
 - número de empregados na empresa, área do estabelecimento, etc.

Amostragem Estratificada

O método geral

- Em seguida, é feita a **seleção** de amostras **dentro** de cada um dos **estratos**, de forma **independente**.
 - A amostra final é formada então pela união das amostras selecionadas em cada um dos estratos.
- Selecione uma amostra s_h de tamanho n_h , com $n_h > 0$, segundo um plano amostral $p_h(s_h)$ *independentemente* dentro de cada estrato h ,
 - $n = \sum_{h=1}^H n_h$ é o tamanho total da amostra selecionada.
- Fica assim assegurado que cada estrato tem sua população representada na amostra completa dada por: $s = s_1 \cup \dots \cup s_h \cup \dots \cup s_H$.
 - Pela definição dos estratos, as amostras nos vários estratos também são conjuntos mutuamente exclusivos, $s_h \cap s_k = \emptyset$, $h \neq k$.

Exemplo

Considere uma pesquisa feita em uma população de 8 domicílios, onde são conhecidas as variáveis renda familiar (Y) e local do domicílio (L), com os códigos A para região alta e B para baixa (B).

```
N <- 8
domicilio <- 1:N
y <- c( 13, 17, 6, 5, 10, 12, 19, 6)
l <- c( "B", "A", "B", "B", "B", "A", "A", "B")
```

domicilio	1	2	3	4	5	6	7	8
y	13	17	6	5	10	12	19	6
l	B	A	B	B	B	A	A	B

- 1 Calcule $Var(\bar{y})$ sob AASc, para estimar $\bar{Y} = \frac{T}{N} = \frac{\sum_{i \in U} y_i}{N}$, com $n = 4$.
- 2 Calcule $Var(\bar{y}_{AES})$, para $\bar{y}_{AES} = \frac{N_A \bar{y}_A + N_B \bar{y}_B}{N}$ (usando L como variável estratificadora), com amostra $n_h = 2$ por estrato.
- 3 Compare as variâncias dos dois planos (Efeito do Plano Amostral EPA).

Exemplo

Resolução:

$N = 8$ domicílios, $N_A = 3$, $N_B = 8$;
 L : localidade domicílio, $H = 2$;
 Y : renda familiar.

1 Sob AASc $Var(\bar{y}) = Var_y/n$,

2 Para $Var(\bar{y}_{AES})$, precisamos
 $Var(\bar{y}_A) = ?$ e $Var(\bar{y}_B) = ?$,

3 Então $EPA = \frac{Var(\bar{y}_{AES})}{Var(\bar{y}_{AASc})} = ?$

domicilio	1	2	3	4	5	6	7	8
y	13	17	6	5	10	12	19	6
l	B	A	B	B	B	A	A	B

```
n <- 4
Ybarra <- mean(y)
vary <- sum( (y-Ybarra)^2 ) / N
varybarra <- vary / n
```

```
yA <- y[l=="A"]; yB <- y[l=="B"]
N_A <- length(yA); N_B <- length(yB)
nA <- nB <- 2
```

... continuar...

Amostragem Estratificada

O método geral

- A independência da amostragem nos diferentes **estratos** permite olhar como **populações separadas**. Uma implementação segue o algoritmo:
 1. Defina a **estratificação** da população U .
 2. Defina o **método para selecionar** a amostra em cada um dos estratos.
 3. **Selecione a amostra** de cada estrato usando o método definido em (2).
 4. **Reúna as amostras** dos vários estratos formando a amostra da pesquisa.

Amostragem Estratificada

Importância

1. Quando os **estratos** formam **domínios “naturais”** ou de interesse,
 - ex. regiões geográficas, tipos de empresas (farmácias, supermercados, lojas de departamentos) etc.,
 - a estratificação garante a seleção de amostras de tamanhos especificados em todos os estratos formados,
 - permite controlar a precisão esperada de estimativas para subgrupos da população de pesquisa definidos como estratos ou agregações de estratos.
2. Pode tornar a **amostra mais “representativa”** e
 - assegurar que todas as partes (estratos) relevantes da população sejam incluídas na amostra.

Amostragem Estratificada

Importância

3. Para **melhorar a eficiência** amostral, **reduzir a variância** dos estimadores dos parâmetros de interesse:

- quanto maior for a **homogeneidade dentro dos estratos**,
- mais a estratificação permite aumentar a precisão de estimativas, em comparação com planos de igual tamanho de amostra que não usam estratificação.

4. Se necessário usar **métodos diferentes de coleta** em diferentes subgrupos da população;

- a estratificação favorece a administração e implementação da coleta em pesquisas onde as condições de pesquisa variam entre os estratos;
- ex. estratos podem ser formados de modo a viabilizar o emprego de modos alternativos de coleta (presencial, telefone, internet, etc.).

Amostragem Estratificada

Características

- Para pesquisas em que a **estimação** é objetivo:
 - o **processo de amostragem e estimação** deve ser replicado separadamente em cada estrato.
- Para pesquisas onde **não são de interesse** resultados **por estrato**,
 - **parâmetros dos estratos** são estimados separadamente, de acordo com o plano amostral adotado,
 - então as **estimativas** são **agregadas** para obter estimativas referentes ao conjunto da população.
- Como **desvantagens** potenciais do método
 - requerer a **reestruturação do cadastro** antes da amostragem.
 - apenas **uma estratificação** é possível e, uma vez fixada a estratificação, a amostragem vai depender dela de forma direta.
 - subdividir em **muitos estratos** pode levar a amostras muito pequenas em cada estrato e complicações como não resposta, ou 'instabilidade nas estimativas'.

Tipos de Estratificação

Tipos de Estratificação

1. Natural - quando os estratos são iguais a subgrupos da população para os quais se requer estimativas com precisão controlada.

- O processo requer essencialmente ouvir os clientes ou usuários dos resultados da pesquisa.
- São eles que devem indicar que subgrupos da população requerem estimativas com precisão controlada.
- Ex. pesquisas do IBGE, que além de produzir resultados para o país como um todo, têm que produzir também resultados por unidades da federação.
- Estas são então *estratos naturais* nas pesquisas, que passam a ter suas amostras planejadas de modo a ter seleção independente em cada unidade da federação, sendo tais amostras de tamanhos suficientes para estimar com a precisão desejada em cada uma.

Tipos de Estratificação

2. *Estatística* - quando os estratos são definidos como subgrupos homogêneos da população, visando aumentar eficiência na estimação para a população como um todo.

- Não há interesse específico na estimação de parâmetros dos estratos formados.
- sua formação pode ser feita empregando métodos que visam a otimizar os efeitos da estratificação.
- Alguns destes métodos são apresentados na sequência.

Tipos de Estratificação

- Na **prática**, não é incomum encontrar aplicações onde a estratificação usada numa pesquisa **combina os dois tipos**.
 - Ex. Na **amostragem de pesquisas econômicas estruturais do IBGE** as empresas são estratificadas por **unidade da federação e tipo de atividade econômica**, definindo assim seus **estratos naturais**.
 - Dentro destes estratos, para **aumentar a eficiência** da amostragem, as empresas são estratificadas por faixas de tamanho, usando a variável **pessoal ocupado, estratificação estatística**, pois tais pesquisas não buscam estimar parâmetros populacionais nestes estratos de tamanho (dentro dos estratos naturais). Ver IBGE(2000).

Há diversos fatores que influenciam a **eficiência na AE**:

- A(s) variável(is) de estratificação.
- O número de estratos.
- A determinação dos limites dos estratos.
- A alocação da amostra nos estratos.
- O método de seleção da amostra em cada estrato.

Tipos de Estratificação

- Para **estratificação natural**, a escolha da(s) variável(is) de estratificação se dá considerando TODAS as variáveis disponíveis necessárias para definir os domínios de interesse.
- No caso da **estratificação estatística**, a escolha deve priorizar, entre as variáveis disponíveis, as que são as *melhores preditoras* da(s) variável(is) de interesse da pesquisa. Para ganhar eficiência a ideia é tornar os valores da(s) variável(is) de estudo dentro de cada estrato mais similares / homogêneos possíveis; minimizar a *variância dentro dos estratos*.
- Nos dois casos é **fundamental** ter acesso a **cadastro(s)** com informações completas sobre variáveis auxiliares que são necessárias para estratificar a população de forma eficiente.

Exemplos de possíveis planos de AE

Exemplos de possíveis planos

Amostragem com estratos definidos por conveniência administrativa

- Considere uma **população de passageiros** chegando a um **terminal marítimo**,
 - navios carregam tanto passageiros viajando com seus **automóveis** como passageiros que viajam **a pé**.
 - ex. *UK International Passenger Survey* (Horsfield, 2017).
- Objetivo: selecionar uma amostra de passageiros para **estimar a média dos gastos feitos na viagem** por passageiro.

Automóvel - estrato 1

- Ex. *Amostragem Sistemática* para selecionar um de cada K automóveis cruzando um ponto de fluxo na saída do navio.
- As unidades de amostragem são os automóveis (com 1 ou mais passageiros), **Amostragem conglomerada**.

Passageiros a pé - estrato 2

- Ex. *Amostragem Binomial* para selecionar passageiros ao passarem por um ponto de fluxo na saída do navio.
- As unidades de amostragem seriam os passageiros individualmente.

Exemplos de possíveis planos

Amostragem Estratificada por Corte - AEC

- Muito usado em pesquisas de **estabelecimentos** ou **instituições**, em populações onde há grande **assimetria** das principais variáveis de interesse.
- Estratos formados por **partes da população** onde existe **grande heterogeneidade** ou que **concentram grande parte do total** de uma ou mais variáveis de interesse, porém compostas de um **número relativamente pequeno** de unidades populacionais,
 - Chamado *estrato certo*, nele se faz um **censo**. Nos demais estratos são pesquisadas amostras de suas unidades.
- Ex. **pesquisas econômicas** na área da **indústria** onde um número pequeno de estabelecimentos industriais é responsável por grande parte do valor da produção.
 - Neste caso, a precisão das estimativas de totais populacionais produzidas pode ser maior com **AEC** em comparação com **AAS**.
 - Como no **estrato certo** é feito um **censo**, não há variabilidade devida ao uso de amostragem nesse estrato (variância nula do total 'estimado' nesse estrato).

Exemplos de possíveis planos

Amostragem estratificada simples

- **Diferentes planos amostrais** podem ser empregados nos diversos estratos, mas isso é **pouco comum na prática**. O mais comum é usar um mesmo tipo de amostragem nos vários estratos definidos.
- A *Amostragem Estratificada Simples - AES* é o caso mais simples, em que uma **AAS** é selecionada em cada um dos estratos.
 - Neste caso, deve estar disponível um cadastro que permita alocar as unidades da população U nos estratos definidos, conhecer os tamanhos dos estratos, e o cadastro deve estar organizado de forma a permitir a seleção da amostra em cada um dos estratos.
- Veremos agora resultados para **AES**, mas o mesmo tipo de enfoque pode ser adaptado quando for utilizado qualquer outro método de seleção nos estratos,
 - tais como *Amostragem Sistemática*, *Amostragem Binomial*, *Amostragem com PPT*, etc.
 - A **seleção é independente** nos diferentes estratos, basta fazer as estimativas utilizando as fórmulas adequadas ao método de seleção em cada estrato, então agregar os resultados dessas estimativas de

AES, parâmetros e estimadores

Amostragem estratificada simples

Método de seleção

- Para cada estrato $h = 1, 2, \dots, H$, selecione por AASs uma amostra s_h de tamanho $1 \leq n_h \leq N_h$ das N_h unidades do estrato U_h (independente da seleção feita nos outros estratos).
- Qualquer algoritmo para seleção de amostras AASs pode ser empregado para a seleção das amostras nos estratos.
- O conjunto de todas as amostras possíveis S_{AES} é formado por amostras da forma:

$$s = s_1 \cup \dots \cup s_h \cup \dots \cup s_H =.$$

- O tamanho é dado pelo produto dos tamanhos dos conjuntos de amostras possíveis em cada um dos estratos.

$$\#S_{AES} = \#s_1 \times \dots \times \#s_H = \prod_{h=1}^H \binom{N_h}{n_h} = \nu.$$

Amostragem estratificada simples

Método de seleção

- Assim, na **AASs** em cada estrato, temos o plano amostral:

$$p_h(s_h) = 1 / \binom{N_h}{n_h} = \binom{N_h}{n_h}^{-1}, \forall h = 1, 2, \dots, H.$$

- Em consequência, o plano amostral $p_{AES}(s)$ é dado por:

$$p_{AES}(s) = \prod_{h=1}^H p_h(s_h) = \prod_{h=1}^H \binom{N_h}{n_h}^{-1}$$

onde $s \in S_{AES}$.

O tamanho total da amostra é:

$$n = n_1 + n_2 + \dots + n_H.$$

Amostragem estratificada simples

Parâmetros nos estratos

- **Total** populacional do **estrato** h :

$$T_h = \sum_{i \in U_h} y_i$$

- **Média** populacional do **estrato** h

$$\overline{Y}_h = T_h / N_h = \frac{1}{N_h} \sum_{i \in U_h} y_i$$

- **Variância** do **estrato** h

$$S_h^2 = \frac{1}{N_h - 1} \sum_{i \in U_h} (y_i - \overline{Y}_h)^2 \quad \text{ou} \quad Var_h = \frac{N_h - 1}{N_h} S_h^2.$$

Amostragem estratificada simples

Parâmetros globais

- O **total populacional**:

$$T = \sum_{h=1}^H Y_h = \sum_{h=1}^H N_h \bar{Y}_h$$

- A **média populacional**:

$$\bar{Y} = T/N = \frac{1}{N} \sum_{h=1}^H N_h \bar{Y}_h = \sum_{h=1}^H W_h \bar{Y}_h,$$

onde $W_h = N_h/N$ é o *peso* da média do estrato h na composição de \bar{Y} .

- A **variância populacional** pode ser escrita como

$$S_y^2 = \frac{1}{N-1} \sum_{h=1}^H \sum_{i \in U_h} (y_i - \bar{Y})^2 \quad \text{ou} \quad Var_y = \frac{1}{N} \sum_{h=1}^H \sum_{i \in U_h} (y_i - \bar{Y})^2 = \frac{N-1}{N} S_y^2.$$

Amostragem estratificada simples

Parâmetros globais

- A variância populacional S_y^2 pode ser escrita como:

$$\begin{aligned} S_y^2 &= \frac{1}{N-1} \sum_{h=1}^H \sum_{i \in U_h} (y_i - \bar{Y})^2 \\ &= \frac{1}{N-1} \sum_{h=1}^H \sum_{i \in U_h} \left[(y_i - \bar{Y}_h) + (\bar{Y}_h - \bar{Y}) \right]^2 \\ &= \frac{1}{N-1} \sum_{h=1}^H (N_h - 1) S_h^2 + \frac{1}{N-1} \sum_{h=1}^H N_h (\bar{Y}_h - \bar{Y})^2 \\ &= S_D^2 + S_E^2, \end{aligned}$$

onde $S_D^2 = \sum_{h=1}^H \frac{N_h - 1}{N - 1} S_h^2$ e $S_E^2 = \sum_{h=1}^H \frac{N_h}{N - 1} (\bar{Y}_h - \bar{Y})^2$

- ou

$$Var_y = \sum_{h=1}^H W_h Var_h + \sum_{h=1}^H W_h (\bar{Y}_h - \bar{Y})^2 = Var_D + Var_E$$

Amostragem estratificada simples

Parâmetros globais

- $S_y^2 = S_D^2 + S_E^2$ ou $Var_y = Var_D + Var_E$ sugerem uma **decomposição** útil da variância total da variável y na população.
 - As componentes são conhecidas como **Variância Dentro** e **Variância Entre** estratos.
- Selecionar **amostras** de forma **independente** em **todos** os **estratos**, a amostragem estratificada **elimina** a componente de **variação entre** os estratos ao estimar parâmetros do conjunto da população, ex. o total ou a média.
- Para uma **variância total** S_y^2 **fixada**, **minimizar** a **Variância Dentro** S_D^2 , ao definir estratos homogêneos (em relação à variável de interesse), deve reduzir grande parte da variação relevante para a estimação.

Amostragem estratificada simples

Estimação no estrato h

Temos **amostragem independentemente** em cada estrato, então os seguintes **estimadores**:

- do **total** T_h do **estrato** h ,

$$\hat{T}_h = \sum_{i \in s_h} d_i y_i = \frac{N_h}{n_h} \sum_{i \in s_h} y_i = N_h \bar{y}_h;$$

onde $d_i = N_h/n_h = \pi_i^{-1}$ é o peso das unidades i dentro do estrato h .

- da **média** \bar{Y}_h do **estrato** h ,

$$\bar{y}_h = \frac{1}{n_h} \sum_{i \in s_h} y_i;$$

- da **variância** S_h^2 ou Var_h do estrato h ,

$$\hat{S}_h^2 = \frac{1}{n_h - 1} \sum_{i \in s_h} (y_i - \bar{y}_h)^2 = s_h^2.$$

Amostragem estratificada simples

Estimação no estrato h

- Se temos **AASs** de n_h unidades **dentro do estrato h** , **sabemos que** são válidas as seguintes propriedades:

- $E_{AES}(\hat{T}_h) = T_h$

- $E_{AES}(\bar{y}_h) = \bar{Y}_h$

- $E_{AES}(\hat{S}_h^2) = S_h^2 \quad \Rightarrow \hat{S}_h^2 \text{ é ENV de } S_h^2 \text{ sob AASs}$

- Os resultados decorrem das **propriedades** de **estimadores** sob **AASs**.
- Sabemos mostrar esses resultados???
- E na **AASc**???

- $E_{AES}(\hat{S}_h^2) = Var_h \quad \Rightarrow \hat{S}_h^2 \text{ é ENV de } Var_h \text{ sob AASc}$

Amostragem estratificada simples

Estimação no estrato h

- **Variâncias** de estimadores de média e total por estrato na **AASs**:

Total	Média
$Var_{AES}(\hat{T}_h) = N_h^2 Var_{AES}(\bar{y}_h)$	$Var_{AES}(\bar{y}_h) = \left(\frac{1}{n_h} - \frac{1}{N_h}\right) S_h^2$
$\widehat{Var}_{AES}(\hat{T}_h) = N_h^2 \widehat{Var}_{AES}(\bar{y}_h)$	$\widehat{Var}_{AES}(\bar{y}_h) = \left(\frac{1}{n_h} - \frac{1}{N_h}\right) \hat{S}_h^2$

- E na **AASc**???

Total	Média
$Var_{AESc}(\hat{T}_h) = N_h^2 Var_{AESc}(\bar{y}_h)$	$Var_{AESc}(\bar{y}_h) = \frac{1}{n_h} Var_h$
$\widehat{Var}_{AESc}(\hat{T}_h) = N_h^2 \widehat{Var}_{AESc}(\bar{y}_h)$	$\widehat{Var}_{AESc}(\bar{y}_h) = \frac{1}{n_h} \hat{S}_h^2$

Amostragem estratificada simples

Estimação de parâmetros globais

- O estimador do total T : $\hat{T}_{AES} = \sum_{h=1}^H \hat{T}_h = \sum_{h=1}^H N_h \bar{y}_h$.
- O estimador da média \bar{Y} : $\bar{y}_{AES} = \sum_{h=1}^H W_h \bar{y}_h = \sum_{h=1}^H \frac{N_h}{N} \bar{y}_h$.

O **estimador** da média populacional sob **AES** é **não viciado**, isto é:

$$E_{AES}(\bar{y}_{AES}) = \bar{Y}$$

Isto segue porque $E_{AES}(\bar{y}_h) = \bar{Y}_h, \forall h = 1, \dots, H$, e

$$E_{AES}\left(\sum_{h=1}^H W_h \bar{y}_h\right) = \sum_{h=1}^H W_h E_{AES}(\bar{y}_h) = \sum_{h=1}^H W_h \bar{Y}_h = \bar{Y}.$$

Amostragem estratificada simples

Estimação de parâmetros globais

- Para estimar a **variância do estimador do total** e da **média**, respectivamente, (dado **AASs** dentro dos estratos)

$$Var_{AES} \left(\hat{T}_{AES} \right) = \sum_{h=1}^H N_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$$

e

$$Var_{AES} \left(\bar{y}_{AES} \right) = \sum_{h=1}^H W_h^2 Var_{AES} \left(\bar{y}_h \right) = \sum_{h=1}^H \frac{N_h^2}{N^2} \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2,$$

- temos os **ENVs** com as expressões dadas por

$$\widehat{Var}_{AES} \left(\hat{T}_{AES} \right) = \sum_{h=1}^H N_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) \hat{S}_h^2$$

e

$$\widehat{Var}_{AES} \left(\bar{y}_{AES} \right) = \sum_{h=1}^H \frac{N_h^2}{N^2} \left(\frac{1}{n_h} - \frac{1}{N_h} \right) \hat{S}_h^2.$$

- E quanto a **AASc**???

Amostragem estratificada simples

Intervalo de confiança para a média \bar{Y}

Se $n = \sum_{h=1}^H n_h$ for grande, então o Teorema Central do Limite se aplica:

$$\frac{\bar{y}_{AES} - \bar{Y}}{\sqrt{\widehat{Var}_{AES}(\bar{y}_{AES})}} \approx Normal(0; 1)$$

Logo, um intervalo de confiança de nível $1 - \alpha$ para \bar{Y} é dado por:

$$IC_{AES}(\bar{Y}; 1 - \alpha) = \left[\bar{y}_{AES} \mp z_{\alpha/2} \sqrt{\widehat{Var}_{AES}(\bar{y}_{AES})} \right]$$

Amostragem estratificada simples

Intervalo de confiança para a média do estrato \bar{Y}_h

Se os tamanhos de amostras *por estratos* n_h são suficientemente grandes, o Teorema Central do Limite também indica que:

$$\frac{\bar{y}_h - \bar{Y}_h}{\sqrt{\widehat{Var}_{AES}(\bar{y}_h)}} \approx Normal(0; 1)$$


e então um intervalo de confiança de nível $1 - \alpha$ para \bar{Y}_h é dado por:

$$IC_{AES}(\bar{Y}_h; 1 - \alpha) = \left[\bar{y}_h \mp z_{\alpha/2} \sqrt{\widehat{Var}_{AES}(\bar{y}_h)} \right]$$

Para casa

- Continuar o Exemplo.
- Mostrar $E_{AES}(\hat{T}_{AES}) = T$.
- Encontre $Var_{AES}(\hat{T}_{AES})$, tanto para **AASs** quanto para **AASc**.
- Fazer exercícios.
- Rever os slides.
- Ler a partir seção 11.3 do livro 'Amostragem: Teoria e Prática Usando R'.

Próxima aula

- Amostragem Estratificada
 - Alocação de amostras nos estratos
- Laboratório de 

Muito obrigado!



Fonte: imagem do livro *Combined Survey Sampling Inference: Weighing of Basu's Elephants: Weighing Basu's Elephants*.

Resumo da notação

Parâmetros no estrato h

- Total - $T_h = \sum_{i \in U_h} y_i$
- Média - $\bar{Y}_h = T_h / N_h = \frac{1}{N_h} \sum_{i \in U_h} y_i$
- Variância - $S_h^2 = \frac{1}{N_h - 1} \sum_{i \in U_h} (y_i - \bar{Y}_h)^2$ ou $Var_h = Var_{h,y} = \frac{N_h - 1}{N_h} S_h^2$

Parâmetros globais

- Total - $T = \sum_{h=1}^H T_h = \sum_{h=1}^H N_h \bar{Y}_h$
- Média - $\bar{Y} = T / N = \frac{1}{N} \sum_{h=1}^H N_h \bar{Y}_h = \sum_{h=1}^H W_h \bar{Y}_h$, $W_h = N_h / N$
- Variância - $S^2 = \frac{1}{N - 1} \sum_{h=1}^H \sum_{i \in U_h} (y_i - \bar{Y})^2$ ou $Var_y = \frac{1}{N} \sum_{h=1}^H (N_h - 1) S_h^2$

Decomposição da variância populacional

$$S_y^2 = \frac{1}{N - 1} \sum_{h=1}^H (N_h - 1) S_h^2 + \frac{1}{N - 1} \sum_{h=1}^H N_h (\bar{Y}_h - \bar{Y})^2 = S_D^2 + S_E^2$$

ou

$$Var_y = \sum_{h=1}^H W_h Var_h + \sum_{h=1}^H W_h (\bar{Y}_h - \bar{Y})^2 = Var_D + Var_E.$$

Resumo da notação

Estimadores no estrato h

Estimadores AASc	Estimadores AASs
$\hat{T}_h = \frac{N_h}{n_h} \sum_{i \in s_h} y_i = N_h \bar{y}_h$	$\hat{T}_h = \frac{N_h}{n_h} \sum_{i \in s_h} y_i = N_h \bar{y}_h$
$\bar{y}_h = \frac{1}{n_h} \sum_{i \in s_h} y_i$	$\bar{y}_h = \frac{1}{n_h} \sum_{i \in s_h} y_i$
$Var_{AESc}(\hat{T}_h) = N_h^2 Var_{AESc}(\bar{y}_h)$	$Var_{AES}(\hat{T}_h) = N_h^2 Var_{AES}(\bar{y}_h)$
$Var_{AESc}(\bar{y}_h) = \frac{1}{n_h} Var_h$	$Var_{AES}(\bar{y}_h) = \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$
$\widehat{Var}_{AESc}(\hat{T}_h) = N_h^2 \widehat{Var}_{AESc}(\bar{y}_h)$	$\widehat{Var}_{AES}(\hat{T}_h) = N_h^2 \widehat{Var}_{AES}(\bar{y}_h)$
$\widehat{Var}_{AESc}(\bar{y}_h) = \frac{1}{n_h} \hat{S}_h^2$	$\widehat{Var}_{AES}(\bar{y}_h) = \left(\frac{1}{n_h} - \frac{1}{N_h} \right) \hat{S}_h^2$

em que $Var_h = Var_h(y) = \frac{N_h-1}{N_h} S_h^2$ e $\hat{S}_h^2 = \frac{1}{n_h-1} \sum_{i \in s_h} (y_i - \bar{y}_h)^2$.

Resumo da notação

Estimadores globais

- Do total T : $\hat{T}_{AES} = \sum_{h=1}^H \hat{T}_h = \sum_{h=1}^H N_h \bar{y}_h$.
- Da média \bar{Y} : $\bar{y}_{AES} = \sum_{h=1}^H W_h \bar{y}_h = \sum_{h=1}^H \frac{N_h}{N} \bar{y}_h$.

Variância do estimador e seu estimador

Sob AASc	Sob AASs
$Var_{AES}(\hat{T}_{AES}) = \sum_{h=1}^H N_h^2 \frac{Var_h}{n_h}$	$Var_{AES}(\hat{T}_{AES}) = \sum_{h=1}^H N_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$
$Var_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 \frac{Var_h}{n_h}$	$Var_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$
$\widehat{Var}_{AES}(\hat{T}_{AES}) = \sum_{h=1}^H N_h^2 \frac{\hat{S}_h^2}{n_h}$	$\widehat{Var}_{AES}(\hat{T}_{AES}) = \sum_{h=1}^H N_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) \hat{S}_h^2$
$\widehat{Var}_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 \frac{\hat{S}_h^2}{n_h}$	$\widehat{Var}_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) \hat{S}_h^2$

Referências

Slides baseados no Capítulo 11 do livro

- Amostragem: Teoria e Prática Usando o R

Citações do Capítulo

- Horsfield(2017)
- IBGE(2000)