

MAT02036 - Amostragem 2

Aula 04 - Amostragem Estratificada - Propriedades e Alocação de amostras

Markus Stein

Departamento de Estatística, IME/UFRGS

2022/2

Housekeeping

- Aproveitem o momento presencial para tirar dúvidas
- Se estivéssemos no ensino remoto ou à distância
 - vocês poderiam estar somente ouvindo, sem interação
 - ou assistindo vídeos e material em outro momento
- Depois das aulas, rever material da aula passada
 - fazer exercícios
 - se preparar para a próxima aula

Aula passada

Parâmetros no estrato h

- Total - $T_h = \sum_{i \in U_h} y_i$
- Média - $\bar{Y}_h = T_h / N_h = \frac{1}{N_h} \sum_{i \in U_h} y_i$
- Variância - $S_h^2 = \frac{1}{N_h - 1} \sum_{i \in U_h} (y_i - \bar{Y}_h)^2$ ou $Var_h = Var_{h,y} = \frac{N_h - 1}{N_h} S_h^2$

Parâmetros globais

- Total - $T = \sum_{h=1}^H T_h = \sum_{h=1}^H N_h \bar{Y}_h$
- Média - $\bar{Y} = T / N = \frac{1}{N} \sum_{h=1}^H N_h \bar{Y}_h = \sum_{h=1}^H W_h \bar{Y}_h$, $W_h = N_h / N$
- Variância - $S^2 = \frac{1}{N - 1} \sum_{h=1}^H \sum_{i \in U_h} (y_i - \bar{Y})^2$ ou $Var_y = \frac{1}{N} \sum_{h=1}^H (N_h - 1) S_h^2$

Decomposição da variância populacional

$$S_y^2 = \frac{1}{N - 1} \sum_{h=1}^H (N_h - 1) S_h^2 + \frac{1}{N - 1} \sum_{h=1}^H N_h (\bar{Y}_h - \bar{Y})^2 = S_D^2 + S_E^2$$

ou

$$Var_y = \sum_{h=1}^H W_h Var_h + \sum_{h=1}^H W_h (\bar{Y}_h - \bar{Y})^2 = Var_D + Var_E.$$

Aula passada

Estimadores no estrato h

Estimadores AASc	Estimadores AASs
$\hat{T}_h = \frac{N_h}{n_h} \sum_{i \in s_h} y_i = N_h \bar{y}_h$	$\hat{T}_h = \frac{N_h}{n_h} \sum_{i \in s_h} y_i = N_h \bar{y}_h$
$\bar{y}_h = \frac{1}{n_h} \sum_{i \in s_h} y_i$	$\bar{y}_h = \frac{1}{n_h} \sum_{i \in s_h} y_i$
$Var_{AESc}(\hat{T}_h) = N_h^2 Var_{AESc}(\bar{y}_h)$	$Var_{AES}(\hat{T}_h) = N_h^2 Var_{AES}(\bar{y}_h)$
$Var_{AESc}(\bar{y}_h) = \frac{1}{n_h} Var_h$	$Var_{AES}(\bar{y}_h) = \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$
$\widehat{Var}_{AESc}(\hat{T}_h) = N_h^2 \widehat{Var}_{AESc}(\bar{y}_h)$	$\widehat{Var}_{AES}(\hat{T}_h) = N_h^2 \widehat{Var}_{AES}(\bar{y}_h)$
$\widehat{Var}_{AESc}(\bar{y}_h) = \frac{1}{n_h} \hat{S}_h^2$	$\widehat{Var}_{AES}(\bar{y}_h) = \left(\frac{1}{n_h} - \frac{1}{N_h} \right) \hat{S}_h^2$

em que $Var_h = Var_h(y) = \frac{N_h - 1}{N_h} S_h^2$ e $\hat{S}_h^2 = \frac{1}{n_h - 1} \sum_{i \in s_h} (y_i - \bar{y}_h)^2$.

Aula passada

Estimadores globais

- Do total T : $\hat{T}_{AES} = \sum_{h=1}^H \hat{T}_h = \sum_{h=1}^H N_h \bar{y}_h$.
- Da média \bar{Y} : $\bar{y}_{AES} = \sum_{h=1}^H W_h \bar{y}_h = \sum_{h=1}^H \frac{N_h}{N} \bar{y}_h$.

Variância do estimador e seu estimador

Sob AASc	Sob AASs
$Var_{AES}(\hat{T}_{AES}) = \sum_{h=1}^H N_h^2 \frac{Var_h}{n_h}$	$Var_{AES}(\hat{T}_{AES}) = \sum_{h=1}^H N_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$
$Var_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 \frac{Var_h}{n_h}$	$Var_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$
$\widehat{Var}_{AES}(\hat{T}_{AES}) = \sum_{h=1}^H N_h^2 \frac{\hat{S}_h^2}{n_h}$	$\widehat{Var}_{AES}(\hat{T}_{AES}) = \sum_{h=1}^H N_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) \hat{S}_h^2$
$\widehat{Var}_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 \frac{\hat{S}_h^2}{n_h}$	$\widehat{Var}_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) \hat{S}_h^2$

Ainda aula passada

Tarefa para casa:

Seja \hat{T}_h um estimador não viesado (ENV) para T_h , o total do estrato h , segundo um plano amostral A , ou seja, $E_A(\hat{T}_h) = T_h, \forall h = 1, \dots, H$. De acordo com o plano amostral estratificado simples **AES** responda:

1. Mostrar $E_{AES}(\hat{T}_{AES}) = T$, em que $\hat{T}_{AES} = \sum_{h=1}^H N_h^2 \hat{T}_h$;
2. Encontre $Var_{AES}(\hat{T}_{AES})$, tanto para **AASs** quanto para **AASc**.

Alguém tentou ???

Ainda aula passada

Exercício: Para os dados do exemplo da aula passada (ver abaixo);

1. selecione uma amostra assumindo o plano AAS_c em cada estrato;
2. construa um intervalo de 99% de confiança para a renda média global dos domicílios;
3. construa um intervalo de 99% de confiança para a renda média dos domicílios por estrato.

Iremos explorar os ICs nas próximas aulas !

Alocação da amostra pelos estratos

Exemplo aula passada Alocação UNIFORME

Considere uma pesquisa feita em uma população de 8 domicílios, onde são conhecidas as variáveis renda familiar (Y) e local do domicílio (L), com os códigos A para região alta e B para baixa (B).

```
N <- 8
domicilio <- 1:N
y <- c( 13, 17, 6, 5, 10, 12, 19, 6)
l <- c( "B", "A", "B", "B", "B", "A", "A", "B")
```

domicilio	1	2	3	4	5	6	7	8
y	13	17	6	5	10	12	19	6
l	B	A	B	B	B	A	A	B

1. Calcule $Var(\bar{y})$ sob AASc, para estimar $\bar{Y} = \frac{T}{N} = \frac{\sum_{i \in U} y_i}{N}$, com $n = 4$.
2. Calcule $Var(\bar{y}_{AES})$, para $\bar{y}_{AES} = \frac{N_A \bar{y}_A + N_B \bar{y}_B}{N}$ (usando L como variável estratificadora), com amostra $n_h = 2$ por estrato.
3. Compare as variâncias dos dois planos (Efeito do Plano Amostral EPA).

Exemplo aula passada Alocação UNIFORME

Resolução no :

$N = 8$ domicílios, $N_A = 3$, $N_B = 8$;

L : localidade domicílio, $H = 2$;

Y : renda familiar.

1. Sob AASc $Var(\bar{y}_{AASc}) = Var_y/n$,


```
n <- 4                                # tamanho da amostra
Ybarra <- mean(y)                      # media populacional
vary <- sum((y-Ybarra)^2) / N          # variancia de Y_U
varybarra <- vary / n                 # variancia da media amostral
```

2. $Var(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 Var(\bar{y}_h)$, então precisamos $Var(\bar{y}_A)$ e $Var(\bar{y}_B)$,

```
yA <- y[l=="A"]
N_A <- length(yA)
nA <- 2
YbarraA <- mean(yA)
varyA <- sum((yA-YbarraA)^2)/N_A
varybarraA <- varyA / nA
```

```
yB <- y[l=="B"]
N_B <- length(yB)
nB <- 2
YbarraB <- mean(yB)
varyB <- sum((yB-YbarraB)^2)/N_B
varybarraB <- varyB / nB
```

Exemplo aula passada Alocação UNIFORME

Resolução no :

Combinando as estimativas dos estratos, $Var(\bar{y}_{AES_{un}}) = \sum_{h=1}^2 \left(\frac{N_h}{N}\right)^2 \bar{y}_h =$

```
(varybarraAES <- (N_A/N)^2 * varybarraA + (N_B/N)^2 * varybarraB)
```

```
## [1] 2.40625
```

3 Então $EPA = \frac{Var(\bar{y}_{AES})}{Var(\bar{y}_{AASc})} =$

```
(EPA <- varybarraAES / varybarra)
```

```
## [1] 0.4010417
```

Portanto, a **variância** do estimador foi **reduzida em mais da metade**, com o **mesmo tamanho amostral!!!**

(cont.) Exemplo aula passada

"Alocação PROPORCIONAL"

Com os mesmos dados do exemplo da aula passada, definimos outra estratégia de AES tal que os tamanhos amostrais são diferentes. Assuma agora que $n_A = 1$ e $n_B = 3$, com **AASc** dentro de cada estrato.

1. Encontre $Var_{AES}(\bar{y}_{AES})$.
2. Compare com os resultados de $Var(\bar{y})$ baseados nas estratégias anteriores, **AASc** com $n=4$ e **AES** com $n_A = n_B = 2$.
3. Como ficaria $Var_{AES}(\hat{T})$ para o plano *AASs* dentro de cada estrato?

(cont.) Exemplo aula passada 💪

Alocação "PROPORCIONAL"

Resolução no :

1. Vimos que $Var(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 Var(\bar{y}_h)$, então precisamos $Var(\bar{y}_A)$ e $Var(\bar{y}_B)$,

```
yA <- y[l=="A"]  
N_A <- length(yA)  
nA <- 1  
YbarraA <- mean(yA)  
varyA <- sum((yA-YbarraA)^2)/N_A  
varybarraA <- varyA / nA
```

```
yB <- y[l=="B"]  
N_B <- length(yB)  
nB <- 3  
YbarraB <- mean(yB)  
varyB <- sum((yB-YbarraB)^2)/N_B  
varybarraB <- varyB / nB
```


Combinando as estimativas em cada estrato, $Var(\bar{y}_{AES_{pr}}) = \sum_{h=1}^2 \left(\frac{N_h}{N}\right)^2 \bar{y}_h =$

```
(varybarraAESpr <- (N_A/N)^2 * varybarraA + (N_B/N)^2 * varybarraB)
```

```
## [1] 2.416667
```

Exemplo aula passada

Alocação "PROPORCIONAL"

Resolução no :

2. Então $EPA = \frac{Var(\bar{y}_{AES_{pr}})}{Var(\bar{y}_{AES_{un}})} =$

```
(EPA <- varybarraAESpr / varybarraAES)
```

```
## [1] 1.004329
```

Nesse caso parece não haver grande diferença na redução da variância comparando os planos AES_{un} e AES_{pr} , mas ambos mostram que a variância do estimador foi **reduzida em mais da metade**, em relação a uo plano $AASc$, com o **mesmo tamanho amostral!!!**

Note que não usamos exatamente um plano proporcional, $\frac{n_A}{n} = \frac{1}{4} \neq \frac{3}{8} = \frac{N_A}{N}$.

3. ...continuar...

Alocação da amostra nos estratos

- Uma decisão importante é a forma pela qual o tamanho total da amostra será alocado ou distribuído nos estratos.
- Em *estratos naturais* pode ser de **interesse calcular tamanhos de amostra** para que a estimação de parâmetros dos estratos tenham precisão controlada.
 - O tamanho total da amostra é obtido somando os tamanhos de amostra calculados para os estratos,
 - a alocação nos estratos vem antes da obtenção do tamanho total da amostra.
- Se **não há interesse específico na estimação** de parâmetros dos **estratos** e um tamanho total de amostra foi calculado, é necessário distribuir esse tamanho entre os estratos definidos na população.
- Há duas maneiras principais de alocação da amostra, que pode ser feita de forma *proporcional* ou *desproporcional* aos tamanhos N_h dos estratos.

Alocação Proporcional

Alocação Proporcional

Amostragem estratificada simples com alocação proporcional- AESpr\$

- A **fração amostral** em cada **estrato**, $f_h = n_h/n$, é **constante** e igual à fração amostral da amostra inteira, $f = N_h/N$.
 - Estratos maiores ficam com amostras maiores.

- A **Alocação Proporcional** implica tentar implementar

$$\frac{n_h}{n} = \frac{N_h}{N} \Rightarrow n_h = n \frac{N_h}{N} = nW_h, \quad \forall h = 1, 2, \dots, H.$$

- Os tamanhos de amostra calculados provavelmente não serão números inteiros.
 - Na prática **arredondar** para cima os tamanhos de amostra calculados implica um pequeno aumento em n .
- A amostra sorteada será **auto-ponderada** e o procedimento de estimação poderá ser simplificado.
 - Todas as outras formas de alocação vão resultar em uma alocação *desproporcional* da amostra nos estratos.

Alocação Proporcional

- Com $n_h = nW_h$, temos que $\bar{y}_{AES_{pr}} = \bar{y}$ é ENV da média populacional,

$$\bar{y}_{AES_{pr}} = \sum_{h=1}^H W_h \bar{y}_h = \sum_{h=1}^H W_h \frac{1}{n_h} \sum_{i \in s_h} y_i = \frac{1}{n} \sum_{h=1}^H \sum_{i \in s_h} y_i = \bar{y}$$

- Na **AESpr** Sob **AASs** a **variância** de $\bar{y}_{AES_{pr}}$ simplifica para

$$Var_{AES_{pr}}(\bar{y}_{AES_{pr}}) \doteq \left(\frac{1}{n} - \frac{1}{N} \right) S_D^2$$

- A expressão aproximada tem a mesma forma que no caso da **AASs**, com S_y^2 substituído por S_D^2 .
 - Como $(S_D^2 < S_y^2)$, a **AESpr** geralmente reduz a variância do estimador se comparada com **AASs** de igual tamanho.
- Ou, na **AASc** temos

$$Var_{AES_{pr}}(\bar{y}_{AES_{pr}}) = \frac{1}{n} \sum_{h=1}^H W_h Var_h = \frac{1}{n} Var_D$$

Alocação Proporcional

Podemos verificar que $\frac{W_h^2}{n_h} = \frac{W_h^2}{nW_h} = \frac{W_h}{n}$ e $\frac{W_h^2}{N_h} = \frac{W_h^2}{NW_h} = \frac{W_h}{N}$

- Então na **AASs** temos

$$Var_{AES_{pr}}(\bar{y}_{AES_{pr}}) = Var_{AES_{pr}} \left[\sum_{h=1}^H W_h \bar{y}_h \right]$$

$$\textcolor{red}{?} = \sum_{h=1}^H W_h^2 Var_{AES_{pr}}(\bar{y}_h)$$

$$(\text{def. } \bar{y}_h \text{ na AASs}) = \sum_{h=1}^H W_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$$

$$\begin{aligned} (\text{igualdades acima}) &= \left(\frac{1}{n} - \frac{1}{N} \right) \sum_{h=1}^H W_h S_{h,y}^2 \\ &\doteq \left(\frac{1}{n} - \frac{1}{N} \right) S_D^2, \end{aligned}$$

onde a aproximação no último termo decorre de usar pesos N_h/N em lugar dos pesos $(N_h - 1)/(N - 1)$ como na definição de S_D^2 .

- Na **AASc** ???

Alocação Uniforme

Alocação Uniforme

Amostragem estratificada uniforme- AESun

- O **tamanho amostral** em cada **estrato** é **constante**.
- Procedimento indicado quando se pretende **apresentar estimativas separadas** para cada estrato.
- Na **Alocação Uniforme** temos

$$n_h = \frac{n}{H} = k \quad \text{e} \quad f_h = \frac{k}{N_h}$$

assim

$$\bar{y}_{AES_{un}} = \sum_{h=1}^H W_h \bar{y}_h = \sum_{h=1}^H W_h \frac{1}{k} \sum_{i \in s_h} y_i = \frac{1}{k} \sum_{h=1}^H W_h \sum_{i \in s_h} y_i.$$

Questões

- O estimador da média $\bar{y}_{AES_{un}}$ é ENV para \bar{Y} ?
 - Note que $\bar{y}_{AES_{un}} \neq \bar{y}$, a média amostral \bar{y} é ENV para \bar{Y} na AESun?

Alocação Uniforme

Com $n_h = \frac{n}{H} = k$ e $f_h = \frac{n_h}{N_h} = \frac{k}{N_h}$ temos $N_h = \frac{kN_h}{n_h}$

- sob **AASs** temos

$$Var_{AES_{un}}(\bar{y}_{AES_{un}}) = Var_{AES_{pr}} \left[\sum_{h=1}^H W_h \bar{y}_h \right]$$

$$? = \sum_{h=1}^H W_h^2 Var_{AES_{un}}(\bar{y}_h)$$

$$(\text{def. } \bar{y}_h \text{ na AASs}) = \sum_{h=1}^H W_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_h^2$$

$$\begin{aligned} (\text{igualdades acima}) &= \sum_{h=1}^H W_h^2 \left(\frac{1}{k} - \frac{1}{\frac{kN_h}{n_h}} \right) S_h^2 \\ &= \sum_{h=1}^H W_h^2 \left(1 - \frac{n_h}{N_h} \right) \frac{S_h^2}{k}, \end{aligned}$$

- Na **AASc** $Var_{AES_{un}}(\bar{y}_{AES_{un}}) = \sum_{h=1}^H W_h^2 \frac{Var_h}{k}$

- Sabemos mostrar???

Para casa

- Continuar o Exemplo.
- Mostrar $E_{AES}(\hat{T}_{AES}) = T$.
- Fazer exercícios 11.1 e 11.2 do livro 'Amostragem: Teoria e Prática Usando R' <https://amostragemcomr.github.io/livro/estrat.html#exerc11>
- Fazer exercício 1 da lista 1.
- Rever os slides.
- Ler a partir da seção 11.3 do livro 'Amostragem: Teoria e Prática Usando R'.

Próxima aula

- Amostragem Estratificada
 - continuação alocação de amostras

Muito obrigado!



Fonte: imagem do livro *Combined Survey Sampling Inference: Weighing of Basu's Elephants: Weighing Basu's Elephants*.

Resumo da notação

- Tamanho da amostra no estrato h
 - **Proporcional**, $n_h = nW_h$
 - **Uniforme**, $n_h = n/H$
- Estimadores da média

Alocação	média
Proporcional	$\bar{y}_{AES_{pr}} = \bar{y}$
Uniforme	$\bar{y}_{AES_{un}} = \frac{1}{k} \sum_{h=1}^H W_h \sum_{i \in s_h} y_i$

- Suas variâncias

Alocação	Sob AASc	Sob AASs
Proporcional	$Var(\bar{y}_{AES_{pr}}) = \frac{1}{n} \sum_{h=1}^H W_h Var_h$	$Var(\bar{y}_{AES_{pr}}) = \left(\frac{1}{n} - \frac{1}{N}\right) \sum_{h=1}^H W_h S_h^2$
Uniforme	$Var(\bar{y}_{AES_{un}}) = \frac{1}{k} \sum_{h=1}^H W_h^2 Var_h$	$Var(\bar{y}_{AES_{un}}) = \frac{1}{k} \sum_{h=1}^H W_h^2 \left(1 - \frac{n_h}{N_h}\right) S_h^2$

Referências

Slides baseados no Capítulo 11 do livro

- Amostragem: Teoria e Prática Usando o R

Citações do Capítulo

- Horsfield(2017)
- IBGE(2000)