

MAT02036 - Amostragem 2

Aula 05 - Amostragem Estratificada - Alocação Ótima

Markus Stein

Departamento de Estatística, IME/UFRGS

2022/2

Housekeeping

- Aproveitem o momento presencial para tirar dúvidas
- Se estivéssemos no ensino remoto ou à distância
 - vocês poderiam estar somente ouvindo, sem interação
 - ou assistindo vídeos e material em outro momento
- Depois das aulas, rever material da aula passada
 - fazer exercícios
 - se preparar para a próxima aula

Aula passada

Amostragem estratificada simples com alocação **proporcional** - AES_{pr}

- Com $n_h = nW_h$, a *média amostral simples* é **ENV** da média populacional na *AASs*

$$\bar{y}_{AES_{pr}} = \sum_{h=1}^H W_h \bar{y}_h = \sum_{h=1}^H W_h \frac{1}{n_h} \sum_{i \in s_h} y_i = \frac{1}{n} \sum_{h=1}^H \sum_{i \in s_h} y_i = \bar{y}$$

- A variância de $\bar{y}_{AES_{pr}}$, na **AASs** simplifica para

$$S_{\bar{y}_{AES_{pr}}}^2 = \left(\frac{1}{n} - \frac{1}{N} \right) \sum_{h=1}^H W_h S_{h,y}^2 \doteq \left(\frac{1}{n} - \frac{1}{N} \right) S_D^2,$$

e na **AASc**

$$Var_{AES_{pr}} \left(\bar{y}_{AES_{pr}} \right) = \frac{1}{n} \sum_{h=1}^H W_h Var_h = \frac{1}{n} Var_D$$

Aula passada

- Amostragem estratificada **uniforme** - AES_{un}

$$n_h = \frac{n}{H} = k \quad \text{e} \quad f_h = \frac{k}{N_h}$$

assim

$$\bar{y}_{AES_{un}} = \sum_{h=1}^H W_h \bar{y}_h = \sum_{h=1}^H W_h \frac{1}{k} \sum_{i \in s_h} y_i = \frac{1}{k} \sum_{h=1}^H W_h \sum_{i \in s_h} y_i.$$

Questões

- O estimador da média $\bar{y}_{AES_{un}}$ é ENV para \bar{Y} ?
 - Note que $\bar{y}_{AES_{un}} \neq \bar{y}$, a média amostral \bar{y} é ENV para \bar{Y} na AESun?
- Como fica a expressão de $V_{AES_{un}}(\bar{y}_{AES_{un}})$ nesse caso?

Aula passada

- Alocação da amostra no estrato h
 - **Proporcional**, $n_h = nW_h$
 - **Uniforme**, $n_h = n/H$
- Estimadores da média

Alocação	média
Proporcional	$\bar{y}_{AES_{pr}} = \bar{y}$
Uniforme	$\bar{y}_{AES_{un}} = \frac{1}{k} \sum_{h=1}^H W_h \sum_{i \in s_h} y_i$

- Suas variâncias

Alocação	Sob AASc	Sob AASs
Proporcional	$Var(\bar{y}_{AES_{pr}}) = \frac{1}{n} \sum_{h=1}^H W_h Var_h$	$Var(\bar{y}_{AES_{pr}}) = \left(\frac{1}{n} - \frac{1}{N}\right) \sum_{h=1}^H W_h S_h^2$
Uniforme	$Var(\bar{y}_{AES_{un}}) = \frac{1}{k} \sum_{h=1}^H W_h^2 Var_h$	$Var(\bar{y}_{AES_{un}}) = \frac{1}{k} \sum_{h=1}^H W_h^2 \left(1 - \frac{n_h}{N_h}\right) S_h^2$

Alocação ótima

Alocação ótima

- A maioria das pesquisas convive com **restrições orçamentárias**.
- É sempre possível ganhar eficiência com uso de **AES** em comparação com uma **AAS** de igual tamanho.
- O caminho da **alocação proporcional** não é o caminho que **permite obter o maior ganho** de eficiência possível.
- É nesse contexto que foi desenvolvido o método de **alocação ótima** para amostras estratificadas simples (**AESot**).

Alocação ótima

Função custo

- Seja o **custo total** da pesquisa fixado em C unidades monetárias,
 - uma **função custo** descreve como C varia para diferentes n e alternativas de alocação da amostra nos estratos.
 - Considere uma **função custo linear** dada por

$$C = c_0 + \sum_{h=1}^H n_h c_h \quad \text{ou} \quad C' = C - c_0 = \sum_{h=1}^H n_h c_h$$

- c_0 representa os custos fixos da pesquisa
 - $n_h c_h$ os custos que dependem efetivamente de cada estrato h .
- Na **AES** temos que $Var_{AES}(\bar{y}_{AES})$ é mínima para C fixado ou C é mínimo para $V_{AES}(\bar{y}_{AES})$ fixada.

Alocação ótima

Minimização da Variância

A **variância do estimador** da **média** populacional pode ser escrita como:

$$V_{AES}(\bar{y}_{AES}) = \sum_{h=1}^H W_h^2 S_{h,y}^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) = \sum_{h=1}^H W_h^2 S_{h,y}^2 / n_h - V_0,$$

onde $V_0 = \sum_{h=1}^H W_h^2 S_{h,y}^2 / N_h$.

- V_0 não depende de n_h , para minimizar $V_{AES}(\bar{y}_{AES})$ basta encontrar valores de n_h que minimizem $\sum_{h=1}^H W_h^2 S_{h,y}^2 / n_h$.
- Técnicas de minimização de funções com restrições lineares, ex. o método dos multiplicadores de Lagrange. (?)
- O resultado da minimização corresponde à *alocação ótima* dada por:

$$n_h = n \times \frac{W_h S_{h,y} / \sqrt{c_h}}{\sum_{k=1}^H W_k S_{k,y} / \sqrt{c_k}}, \quad \forall h = 1, \dots, H$$

Proposto por Neyman(1934), em seu artigo seminal que introduziu as bases da amostragem probabilística, definiu a amostragem estratificada e já indicava a

Alocação ótima

Uma via de **demonstrar o resultado** é utilizando a desigualdade de Cauchy-Schwartz.

1. Minimizar $Var_{AES}(\bar{y}_{AES})$ para C' fixado ou C' para $V_{AES}(\bar{y}_{AES})$ fixada é equivalente a minimizar o produto

$$Var_{AES}(\bar{y}_{AES}) C' = \left(\sum_{h=1}^H \frac{W_h^2 S_h^2}{n_h} \right) \left(\sum_{h=1}^H n_h c_h \right).$$

2. A desigualdade diz que

$(\sum_h a_h^2)(\sum_h b_h^2) \geq (\sum_h a_h b_h)$ sendo a igualdade quando $\frac{b_h}{a_h} = k$ (constante).

3. Definindo $a_h = \frac{W_h S_h}{\sqrt{n_h}}$ e $b_h = \sqrt{n_h c_h}$ então

$$\frac{b_h}{a_h} = \frac{\sqrt{n_h c_h}}{\frac{W_h S_h}{\sqrt{n_h}}} = \frac{n_h \sqrt{c_h}}{W_h S_h} = k, \text{ para todo } h = 1, \dots, H.$$

- Temos então que $Var_{AES}(\bar{y}_{AES}) C'$ mínimo quando

$$n_h = k \frac{W_h S_h}{\sqrt{c_h}}$$

Alocação ótima

4. Como $n = \sum_{h=1}^H n_h$ então

$$k = \frac{n}{\sum_{h=1}^H W_h S_h} / \sqrt{c_n}.$$

5. Substituindo em n_h no passo (3) temos

$$n_h = n \frac{\frac{W_h S_h}{c_h}}{\sum_{h=1}^H \frac{W_h S_h}{c_h}}.$$

- n_h na **AESot** é diretamente proporcional a $W_h S_h$ e inversamente proporcional a $\sqrt{c_n}$.

Sob **alocação ótima**, uma amostra maior será selecionada num estrato h sempre que:

- a. O estrato tiver mais unidades, N_h grande.
- b. A variabilidade no estrato for maior, $S_{h,y}$ grande.
- c. O custo de amostragem no estrato for menor, c_h pequeno.

Alocação (ótima) de Neyman

- Quando $S_h = S^*$ e $c_h = c^*$, $\forall h = 1, 2, \dots, H$, ambos constantes,

$$n_h = nN_h/N$$

a **alocação ótima coincide** com a **alocação proporcional**.

- Entretanto, se apenas os custos de amostragem forem constantes ao longo dos estratos, $c_h = c^*$, $\forall h = 1, 2, \dots, H$, então:

$$n_h = n \times \frac{N_h S_{h,y}}{\sum_{k=1}^H N_k S_{k,y}}$$

gerando a chamada *Alocação (Ótima) de Neyman*.

- Ex. pesquisas de estabelecimentos quando os **desvios padrões** $S_{h,y}$ **crescem com o tamanho das unidades**, maior variação em estabelecimentos maiores.

Alocação (ótima) de Neyman

- Se *amostragem estratificada simples com alocação de Neyman - AESne* é usada,
 - então o valor da **variância minimizada** para o estimador da média populacional é dado por:

$$Var_{AESne}(\bar{y}_{AES}) = \frac{1}{n} \left(\sum_{h=1}^H W_h S_{h,y} \right)^2 - \frac{1}{N} \left(\sum_{h=1}^H W_h S_{h,y}^2 \right)$$

- O segundo termo à direita corresponde à *correção de população finita*.
 - A Expressão é obtida pela substituição de n_h na expressão da variância do estimador pela expressão do n_h da alocação de Neyman.
- E no plano **AESne** mas agora sob **AASc?**

Alocação (ótima) de Neyman

- sob AASc dentro dos estratos

$$Var_{AES_{ne}}(\bar{y}_{AES}) = Var_{AES_{ne}}\left(\sum_{h=1}^H W_h \bar{y}_h\right)$$

$$(?) = \sum_{h=1}^H W_h^2 Var_{AES_{ne}}(\bar{y}_h)$$

$$(\text{def. AASc dentro}) = \sum_{h=1}^H W_h^2 \frac{Var_h}{n_h}$$

$$(n_h \text{ na } AES_{ne}) = \sum_{h=1}^H W_h^2 \frac{Var_h}{n \frac{\sum_{k=1}^H \sqrt{Var_k} N_k}{\sqrt{Var_h} N_h}} = \sum_{h=1}^H \frac{N_h^2}{N^2} \frac{Var_h}{n} \frac{\sum_{k=1}^H \sqrt{Var_k} N_k}{\sqrt{Var_h} N_h}$$

$$= \frac{1}{n} \sum_{h=1}^H W_h \sqrt{Var_h} \sum_{k=1}^H \frac{\sqrt{Var_k} N_k}{N} = \frac{1}{n} \sum_{h=1}^H W_h \sqrt{Var_h} \sum_{k=1}^H W_k \sqrt{Var_k}$$

$$(?) = \frac{1}{n} \left(\sum_{h=1}^H W_h \sqrt{Var_h} \right)^2 = \frac{\overline{DP}}{n}$$

para $DP_h = \sqrt{Var_h}$ e $\overline{DP} = \sum_{h=1}^H W_h DP_h$.

Exemplo

Exercício 4.1 do livro "Elementos de Amostragem" (Bolfarine e Bussab)

Uma população está dividida em 5 estratos. Os tamanhos dos estratos N_h , médias \bar{Y} e variâncias S_h^2 são dados na tabela abaixo.


h	N_h	\bar{Y}	S_h^2
1	117	7,3	1,31
2	98	6,9	2,03
3	74	11,2	1,13
4	41	9,1	1,96
5	45	9,6	1,74

- Calcule os parâmetros globais \bar{Y} e Var_y .
- Para uma amostra de tamanho $n = 80$, determine as alocações proporcional e (ótima) de Neyman.
- Compare as variâncias dos estimadores obtidos sob **AASc** e **AESne**.
- Faça o mesmo para a **AASc** e a **AESpr**.

Para casa

- Continuar o Exemplo.
- Mostrar $V_{AES}(\bar{y}_{AES_{ne}}) \leq V_{AES_{pr}}(\bar{y}_{AES}) \leq V_{AAS}(\bar{y})$ sob **AASc** dentro dos estratos.
- Fazer exercício 11.5 do livro 'Amostragem: Teoria e Prática Usando R'
<https://amostragemcomr.github.io/livro/estrat.html#exerc11>
- Fazer exercício 1 da lista 1.
- Rever os slides.

Próxima aula

- Amostragem Estratificada
 - Mais sobre Comparação de alternativas de alocação da amostra, efeito do Plano Amostral
- Laboratório de 

Muito obrigado!



Fonte: imagem do livro *Combined Survey Sampling Inference: Weighing of Basu's Elephants: Weighing Basu's Elephants*.

Resumo da notação

Alocação ótima

- **Função custo linear:** $C = c_0 + \sum_{h=1}^H n_h c_h$ ou $C' = C - c_0 = \sum_{h=1}^H n_h c_h$.

Alocação	sob AASc dentro	sob AASs dentro
Ótima	$n_h = n \times \frac{W_h \sqrt{Var_{h,y}} / \sqrt{c_h}}{\sum_{k=1}^H W_k \sqrt{Var_{k,y}} / \sqrt{c_k}}$	$n_h = n \times \frac{W_h S_{h,y} / \sqrt{c_h}}{\sum_{k=1}^H W_k S_{k,y} / \sqrt{c_k}}$
de Neyman	$n_h = n \times \frac{N_h \sqrt{Var_{h,y}}}{\sum_{k=1}^H N_k \sqrt{Var_{k,y}}}$	$n_h = n \times \frac{N_h S_{h,y}}{\sum_{k=1}^H N_k S_{k,y}}$

- Variâncias na AESne

Plano dentro	Variância \bar{y}_{AES} na AESne
AASc	$Var_{AES_{ne}}(\bar{y}_{AES}) = \frac{1}{n} \left(\sum_{h=1}^H W_h \sqrt{Var_h} \right)^2 = \frac{\overline{DP}^2}{n}$
AASs	$Var_{AES_{ne}}(\bar{y}_{AES}) = \frac{1}{n} \left(\sum_{h=1}^H W_h S_{h,y} \right)^2 - \frac{1}{N} \left(\sum_{h=1}^H W_h S_{h,y}^2 \right)$

em que $DP_h = \sqrt{Var_h}$ e $\overline{DP} = \sum_{h=1}^H W_h DP_h$.

Referências

Slides baseados no Capítulo 11 do livro

- Amostragem: Teoria e Prática Usando o R

Citações do Capítulo

- Neyman(1934)
- Cochran(1977)